


格之晶计算


Revolutionary All Flash Technology

计算体系和架构的演化




计算体系中的一些痛点

- 全闪存储已经是千亿的市场规模, 但高可靠性仍然依赖价格昂贵的双端口 SSD




- 容器云 (Kubernetes) 逐渐成为主流, 但始终缺乏高性能, 易部署的存储子系统
- GPU/AI 计算架构受限于存储性能, 网络容易成为瓶颈
- 格之晶计算能够彻底解决带宽的瓶颈, 完全释放 GPU 的算力

格之晶互联延伸 PCI Express



GPU/SSD的数据交换



格之晶计算的技术



SSD


格之晶互联
Extended PCIE



GPU




格之晶计算 GPU/SSD 紧耦合 KV Cache AI & LLM




- 基于**格之晶互联**的 GPU/SSD 紧耦合是开创性的计算架构
- 端到端的数据交换完全在延伸的 PCIe 互联中完成
- 数据交换的延迟有数量级的提高

格之晶计算 KFNative™ Ring Extension



- GPU/SSD 配对组合
- 每片 GPU 有专用的计算缓存和 KV-Cache
- GPU 通过相邻的 SSD 交换数据
- 数十倍地增加了 GPU/KV-Cache 的有效带宽

格之晶计算 KFNative™ 推理示例




Case Study of Streaming Computing during LLM Inference

- GPT-3 175B, 96 layer
- Each layer $\sim 1.8\text{B}$, 3.6G Bytes
- Gen6x16 SSD bandwidth $\sim 100\text{GB/s}$
- Model loading time for one layer: $3.6/100 \sim 35\text{ms}$
- Computing: $100\text{K} \times 1.8\text{B} / 1000 \text{ T} \sim 180\text{ms}$


格之晶计算GPU互联






上行 PCIex16



下行 PCIex16





DeepSeek 2机16卡推理示例



Case Study of DeepSeek V3 671B, 37B active

- DeepSeek V3 671B, 37B active, 61 layer
- Hidden Dimension(D_model) 7168
- Top_K 8
- 1K input token
- Computing time ~ 2 x 1K x 37B/150T/16 ~ 30ms

DeepSeek 2机16卡互联比较



带宽

400G

3.2T

All2All
数据传输

2x1024x7168x61x8/50G
~ 140ms

2x1024x7168x61x8/400G
~ 17.5ms

Prefill 耗时

140 + 30 = 170 ms

17.5 + 30 = 47.5 ms

Token/s/GPU
(input)

1k/16/0.17 ~ 368

1k/16/0.048 ~ 1330



格之晶互联系统集成



Hewlett Packard
Enterprise




Lenovo



- 格之晶计算 **KFNative™** 能有效地和各个品牌服务器厂商集成

格之晶互联 GPU/LPU 生态




- 格之晶计算为 GPU/LPU 提供高速互联通道
- 组建 GPU/LPU 超级节点


格之晶计算方案比较

GPU	AMD 9700 Intel Arc B79	沐曦	Nvidia H200
Computing Power	190 Tflops	300 Tflops	990 Tflops
Price	10,000 ¥	~55,000 ¥	~210,000 ¥
	1x Tflops 1x Price	1.5x Tflops 5.5x Price	5x Tflops 20x Price

格之晶计算 – Revolutionize Kubernetes Storage



格之晶计算的技术定位



格之晶计算市场定位

全闪存阵列

超融合

数据中心 / 算力

Market Size

~ 千亿

~ 近千亿

数千亿

Major Player



Many Players

格之晶 计算优势

- Off-the-Shelf components
- Utilizing server from any vendor
- High performance and low CPU utilization

- Native local NVME performance
- Power efficient
- Revolutionary all flash solution for Kubernetes
-

- Converged SSD/Memory Caching
- Native NVME throughput for KV cache
- Boosting data analytics with native flash storage



格之晶计算竞争对手分析

全闪存阵列



格之晶
算

架构



技术实现

- NVME over Fabric as internal bus
- Erasure coding across D-node
- Eliminate Dual-port SSD

- Extended PCIE as internal bus
- Erasure coding across symmetric nodes
- Eliminate Dual-port SSD

应用扩展

D-node 支持大数据 应用程序

超融合模式支持任何 应用程序

格之晶计算市场策略

国内

海外

全闪存/ 超融合

- 和一线 SSD 厂商合作,主打企业级市场
- 和系统集成厂商合作,增加产品附加价值和可区分性, 进入私有云市场

- 以中小企业,学区为出发点,逐步推广产品
- 找品牌服务器厂商合作,进入企业级市场

KFNative™


- 和一线 GPU 厂商合作,进入数据中心
- 和系统集成厂商合作,拓展企业级市场

- 以大学和研究机构为出发点,逐步推广产品
 - 找品牌服务器厂商合作,进入企业级市场
-

格之晶计算发展规划

公司成立

建立 10 人左右的团队
软硬件开发
系统集成调优



创始团队

- 周为, **中科大**, 斯坦福应用物理系硕士。二十多年存储研发经验。有在 Altera, Marvell, SK Hynix 等知名公司任研发和管理工作, 带百人研发团队。拥有存储架构, 互联多项专利。现任 SK Hynix 资深研发总监
- K. Wong, 软件架构总负责, 二十多年软件, 固件, 系统研发经验。Marvell, SK Hynix 主任工程师。
- X. Hu, 技术总负责, 二十多年软件, 固件, 系统研发经验, 资深 Linux 内核开发者, 在多家存储系统公司任高级技术职位